
심층 합성곱 신경망을 이용한 ImageNet 분류

알렉스 크리제프스키
토론토 대학교
kriz@cs.utoronto.ca

일라 수츠케버
토론토 대학교
ilya@cs.utoronto.ca

제프리 E. 힌튼
토론토 대학교
hinton@cs.utoronto.ca

요약

우리는 ImageNet LSVRC-2010 콘테스트에서 120 만 개의 고해상도 이미지를 1,000 개의 서로 다른 분류로 분류하기 위해 크고 심층적인 합성곱 신경망을 훈련시켰습니다. 테스트 데이터에서는 상위 1 위와 상위 5 위 오류율 37.5%와 17.0%를 달성했으며, 이는 이전 최첨단 기술보다 훨씬 우수했습니다. 6 천만 개의 매개변수와 65 만 개의 뉴런을 가진 신경망은 다섯 개의 합성곱 계층으로 구성되어 있으며, 그 뒤에는 맥스-풀링 계층이 있고, 세 개의 완전 연결 계층이 최종 1,000 웨이 소프트맥스를 가지고 있습니다. 학습 속도를 높이기 위해 포화 신경 없이와 매우 효율적인 GPU 합성 연산을 사용했습니다. 완전 연결 층에서 과적합을 줄이기 위해 최근에 개발된 '드롭아웃(dropout)'이라는 정규화 방법을 사용했는데, 이는 매우 효과적임이 입증되었습니다. 또한 이 모델의 변형을 ILSVRC-2012 대회에 출품하여 상위 5 위 오차율 15.3%를 기록했는데, 이는 두 번째로 우수한 출품작이 기록한 26.2%보다 높은 수치입니다.

1 소개

현재 객체 인식 접근법은 기계 학습 기법을 필수적으로 활용하고 있습니다. 성능을 향상시키기 위해 더 큰 데이터셋을 수집하고, 더 강력한 모델을 학습하며, 과적합을 방지하는 더 나은 기법을 사용할 수 있습니다. 최근까지 라벨링된 이미지 데이터셋은 상대적으로 작았으며, 수만 장의 이미지 정도였습니다(예: NORB [16], Caltech-101/256 [8, 9], CIFAR-10/100 [12]). 이 정도 크기의 데이터셋으로는 라벨 보존 변환이 추가될 경우 간단한 인식 작업도 꽤 잘 해결할 수 있습니다. 예를 들어, MNIST 숫자 인식 과제의 현재 최고 오류율(<0.3%)은 인간의 성과에 근접합니다[4]. 하지만 현실적인 환경의 물체는 상당한 변동성을 보이므로, 인식을 배우려면 훨씬 더 큰 훈련 집합을 사용해야 합니다. 실제로 작은 이미지 데이터셋의 한계는 널리 인식되고 있지만(예: Pinto 등[21]), 수백만 장의 이미지가 포함된 라벨링 데이터셋을 수집하는 것이 최근에야 가능해졌습니다. 새로운 대규모 데이터셋에는 수십만 장의 완전

세분화된 이미지로 구성된 LabelMe[23]와 22,000 개 이상의 카테고리에 걸쳐 1,500 만 장 이상의 라벨이 붙은 고해상도 이미지로 구성된 ImageNet[6]가 포함됩니다.

수백만 장의 이미지에서 수천 개의 물체를 배우려면 큰 학습 능력을 가진 모델이 필요합니다. 하지만 객체 인식 작업의 엄청난 복잡성 때문에 ImageNet 처럼 큰 데이터셋으로도 이 문제를 명확히 지정할 수 없으므로, 우리 모델은 우리가 갖지 못한 데이터를 보완할 충분한 사전 지식을 갖추어야 합니다. 합성곱 신경망(CNN)은 이러한 모델 중 하나에 속합니다 [16, 11, 13, 18, 15, 22, 26]. 깊이와 폭을 조절해 용량을 조절할 수 있으며, 강하고 대체로 올바른 효과도 만듭니다. 이미지의 본질에 대한 가정들(즉, 통계량의 정상성과 픽셀 의존성의 국소성). 따라서 비슷한 크기의 층을 가진 표준 피드포워드 신경망과 비교할 때, CNN 은 연결과 매개변수가 훨씬 적어 훈련이 더 쉬워지며, 이론적으로 가장 좋은 성능은 약간 떨어질 가능성이 큼니다.

CNN 의 매력적인 특성과 지역 구조의 상대적 효율성에도 불구하고, 고해상도 이미지에 대규모로 적용하는 데는 여전히 너무 비싸고 있습니다. 다행히도 현재의 GPU 는 2D 컨볼루션의 고도로 최적화된 구현과 결합되어 흥미롭게 큰 CNN 훈련을 용이하게 할 만큼 강력하며, ImageNet 과 같은 최근 데이터셋에는 심각한 과적합 없이 이러한 모델을 훈련시킬 수 있는 충분한 라벨 예제가 포함되어 있습니다.

이 논문의 구체적인 기여는 다음과 같습니다: 우리는 ILSVRC-2010 및 ILSVRC-2012 대회에서 사용된 ImageNet 하위 집합들로 지금까지 가장 큰 합성곱 신경망 중 하나를 학습시켰으며, 이 데이터셋에서 지금까지 보고된 최고의 결과를 달성했습니다. 우리는 2D 컨볼루션 및 컨볼루션 신경망 훈련에 내재된 모든 연산을 고도로 최적화된 GPU 구현체를 작성하여 공개했습니다¹. 우리 네트워크에는 성능을 향상시키고 훈련 시간을 단축하는 여러 새롭고 독특한 기능들이 포함되어 있으며, 이는 3 절에서 자세히 설명합니다. 네트워크 규모 때문에 120 만 개의 훈련 예제가 라벨링되었음에도 불구하고 과적합이 큰 문제였기에, 과적합을 방지하기 위해 4 절에 설명된 여러 효과적인 기법을 사용했습니다. 최종 네트워크는 5 개의 합성곱 계층과 3 개의 완전 연결 계층을 포함하며, 이 깊이가 중요해 보입니다: 모델 매개변수의 1%를 초과하지 않는 합성곱 계층을 제거하면 성능이 떨어진다는 것을 발견했습니다.

결국 네트워크 크기는 현재 GPU 의 메모리 용량과 우리가 허용하는 학습 시간에 의해 제한됩니다. 우리 네트워크는 두 개의 GTX 580 3GB GPU 에서 훈련하는 데 5 일에서 6 일이 걸립니다. 모든 실험은 더 빠른 GPU 와 더 큰 데이터셋이 나올 때까지 기다리는 것만으로도 결과를 개선할 수 있음을 시사합니다.

2 데이터셋

ImageNet 은 약 22,000 개 카테고리에 속하는 1,500 만 장 이상의 라벨이 붙은 고해상도 이미지로 구성된 데이터셋입니다. 이 이미지들은 웹에서 수집되어 아마존의 Mechanical Turk

¹ <http://code.google.com/p/cuda-convnet/>

클라우드소싱 도구를 사용해 인간 라벨러가 라벨링했습니다. 2010 년부터 파스칼 시각 오브젝트 챌린지의 일환으로 매년 열리는 ImageNet 대형 시각 인식 챌린지라는 대회가 시작되었습니다

(ILSVRC)는 구금되었습니다. ILSVRC 는 ImageNet 의 하위 집합을 사용하며, 각 1000 개 카테고리별로 약 1000 장의 이미지를 제공합니다. 총 약 120 만 장의 학습 이미지, 5 만 장의 검증 이미지, 15 만 장의 테스트 이미지가 있습니다.

ILSVRC-2010 은 테스트 세트 라벨이 제공되는 유일한 ILSVRC 버전으로, 대부분의 실험을 이 버전에서 수행했습니다. 또한 ILSVRC-2012 공모전에 모델을 출품했기 때문에, 6 섹션에서는 테스트 세트 라벨이 없는 이 버전의 데이터셋에 대한 결과도 보고합니다. ImageNet 에서는 두 가지 오류율을 보고하는 것이 관례입니다: top-1 과 top-5 로, 상위 5 개 오류율은 모델이 가장 가능성 높은 다섯 라벨 중 올바른 라벨이 없는 테스트 이미지 비율을 의미합니다.

ImageNet 은 가변 해상도 이미지로 구성되어 있지만, 우리 시스템은 일정한 입력 차원을 요구합니다. 따라서 우리는 이미지를 고정된 해상도인 256×256 으로 다운샘플링했습니다. 직사각형 이미지가 주어졌을 때, 먼저 이미지의 짧은 면이 256 길이로 재조정된 후, 결과 이미지에서 중앙 256×256 패치를 잘라냈습니다. 우리는 각 픽셀에서 훈련 집합 내 평균 활동을 빼는 것 외에는 이미지를 다른 방식으로 전처리하지 않았습니다. 그래서 우리는 픽셀의 (중앙) 원시 RGB 값으로 네트워크를 훈련시켰습니다.

3 아키텍처

네트워크 구조는 그림 2 에 요약되어 있습니다. 이 법은 8 개의 학습 계층을 포함하고 있습니다 — 5 개의 합성곱 계층과 3 개의 완전 연결 계층입니다. 아래에서는 우리 네트워크 아키텍처의 새롭거나 독특한 특징들을 설명합니다. 3.1-3.4 절은 중요도를 추정한 순서대로 정렬되어 있으며, 가장 중요한 부분이 먼저입니다.

3.1 ReLU 비선형성

뉴런의 출력 f 를 입력 x 의 함수로 모델링하는 표준 방법은 $f(x) = \tanh(x)$ 또는 $f(x) = (1 + e^{-x})^{-1}$ 입니다. 그라데이트 하강을 포함한 훈련 시간 측면에서 이 포화 비선형성은 비포화 비선형성 $f(x) = \max(0, x)$ 보다 훨씬 느립니다. Nair 와 Hinton [20]에 따라, 이러한 비선형성을 가진 뉴런을 정정선형 단위(ReLU)라고 부른다. ReLU 를 사용하는 딥 컨볼루션 신경망은 tanh 유닛을 사용하는 동등한 네트워크보다 몇 배 더 빠르게 학습합니다. 이는 그림 1 에서 확인할 수 있는데, 이는 특정 4 층 컨볼루션 네트워크에서 CIFAR-10 데이터셋에서 25% 학습 오차에 도달하는 데

필요한 반복 횟수를 보여줍니다. 이 그래프는 전통적인 포화 뉴런 모델을 사용했다면 이렇게 큰 신경망을 실험할 수 없었을 것임을 보여줍니다.

CNN 에서 전통적인 뉴런 모델의 대안을 고려한 것은 우리가 처음이 아닙니다. 예를 들어, Jarrett 등[11]은 비선형성 $f(x) = |\tanh(x)|$ 특히 Caltech-101 데이터셋에서 대조 정규화 후 국소 평균 풀링을 적용하는 방식과 잘 맞습니다. 하지만 이 데이터셋에서는 과적합 방지가 주된 관심사이므로, 그들이 관찰하는 효과는 ReLU 를 사용할 때

보고하는 학습 집합 적합 능력과 다릅니다. 빠른 학습은 대규모 데이터셋에서 학습된 대형 모델의 성능에 큰 영향을 미칩니다.

3.2 다중 GPU에서의 학습




그림 1: ReLU(실선)를 가진 4 층 합성곱 신경망이 CIFAR-10 에서 25%의 훈련 오류율을 기록 하며, 이는 tanh 뉴런(점선)을 가진 동등한 네트워크보다 6 배 빠릅니다. 각 네트워크의 학습률은 훈련을 최대한 빠르게 하기 위해 독립적으로 선택되었습니다. 어떠한 형태의 정규화도 도입되지 않았다. 여기서 보여진 효과의 크기는 네트워크 아키텍처에 따라 다르지만, ReLUs 가 포함된 네트워크는 포화 뉴런을 가진 네트워크보다 지속적으로 몇 배 빠르게 학습합니다.

단일 GTX 580 GPU 는 3GB 의 메모리만 가지고 있어 학습할 수 있는 네트워크의 최대 크기가 제한됩니다. 알고 보니 120 만 개의 훈련 예제가 한 GPU 에 담기에는 너무 큰 네트워크를 훈련시키기에 충분합니다. 그래서 우리는 두 개의 GPU 에 네트워크를 분산시켰습니다. 현재 GPU 는 호스트 머신 메모리를 거치지 않고 서로 메모리에서 직접 읽고 쓸 수 있기 때문에 특히 크로스 GPU 병렬화에 적합합니다. 우리가 사용하는 병렬화 방식은 본질적으로 각 GPU 의 절반(또는 뉴런)을 배치하는 것이며, 추가로 한 가지 팁이 있습니다: GPU 는 특정 계층에서만 통신합니다. 즉, 예를 들어 3 계층의 커널은 2 계층의 모든 커널 맵에서 입력을 받는다는 뜻입니다. 하지만 4 계층의 커널은 같은 GPU 에 위치한 3 계층의 커널 맵에서만 입력을 받습니다. 연결성 패턴을 선택하는 것은 교차 검증에 문제가 있지만, 이를 통해 통신량을 정밀하게 조정하여 계산량의 허용 가능한 비율로 만들 수 있습니다.

결과적인 구조는 Cires 등[5]이 사용한 "기둥 형태" CNN 과 다소 유사하지만, 우리의 기둥들이 독립적이지 않다는 점이 다릅니다(그림 2 참조). 이 방식은 상위 1 위와 상위 5 위 오류율을 각각 1.7%와 1.2% 감소시켜주며, 순오류율은 절반으로 감소합니다. 각 컨볼루션 계층의 여러 커널이 하나의 GPU 로 학습되었습니다. 2GPU 가 있는 네트워크는 1GPU 가 있는 네트워크보다 훈련에 약간 더 짧은 시간이 걸립니다.

3.3 국소 반응 정규화

ReLU 는 포화를 방지하기 위해 입력 정규화가 필요 없다는 바람직한 특성을 가지고 있습니다. 적어도 일부 훈련 예제가 ReLU 에 긍정적인 입력을 제공하면, 그 뉴런에서 학습이 일어납니다. 그러나 우리는 여전히 다음과 같은 국소 정규화 방식이 일반화에 도움이 된다는 것을 발견한다. 는 $a_{x,y}^i$ 위치에 커널 i 를 적용하여 계산된 뉴런의 활동량 으로 나타냅니다. (x,y) 그리고 ReLU 비선형성을 적용하면, 응답 정규화 활동 $b_{ix,y}$ 는 다음과 같이 주어집니다.

$$b_{x,y}^i = a_{x,y}^i / \left(k + \alpha \sum_{j=\max(0,i-n/2)}^{\min(N-1,i+n/2)} (a_{x,y}^j)^2 \right)^\beta$$

여기서 합은 같은 공간 위치에서 n 개의 "인접한" 핵 사상을 가리며, N 은 층 내 핵의 총 수이다. 커널 맵의 순서는 물론 임의적이며 훈련 시작 전에 결정됩니다. 이러한 반응 정규화는 실제 뉴런에서 발견되는 유형에서 영감을 받은 측면 억제²의 한 형태를 구현하여, 서로 다른 커널을 사용해 계산된 뉴런 출력 간에 큰 활동을 두고 경쟁을 만듭니다. 상수 k, n, α, β 는 검증 집합을 사용하여 값을 결정하는 하이퍼파라미터입니다; 우리는 $k = 2, n = 5, \alpha = 10^{-4}, \beta = 0$ 을 사용했습니다.⁷⁵ 특정 계층에서 ReLU 비선형성을 적용한 후 이 정규화를 적용했습니다(섹션 3.5 참조).

이 방식은 Jarrett 등[11]의 국소 대비 정규화 방식과 약간 유사하지만, 저희 방식은 평균 활동을 빼지 않으므로 '밝기 정규화'라고 부르는 것이 더 정확합니다. 응답 정규화는 각각 상위 1 위와 상위 5 위 오류율을 1.4%와 1.2% 감소시킵니다. 또한 CIFAR-10 데이터셋에서 이 방식의 효과를 검증했습니다: 4 층 CNN 은 정규화 없이 13%의 테스트 오류율, 정규화 시 11%의 오류율을 달성²했습니다.

3.4 중첩 풀링

CNN 의 풀링 계층은 동일한 커널 맵 내에서 인접한 뉴런 그룹의 출력을 요약합니다. 전통적으로 인접한 풀링 단위로 요약된 이웃들은 겹치지 않는다(예: [17, 11, 4]). 더 정확히 말하면, 풀링 층은 픽셀 간격이 s 씩 떨어진 풀링 단위들의 격자로 구성되며, 각 집합 단위는 집합 단위 위치를 중심으로 $z \times z$ 의 이웃을 요약하는 것으로 생각할 수 있다. $s = z$ 를 설정하면 CNN 에서 흔히 사용되는 전통적인 국소 풀링을 얻을 수 있습니다. $s < z$ 설정하면 겹치는 풀링이 됩니다. 이것이 우리 네트워크 전반에서 사용하는 방식으로, $s = 2, z = 3$ 입니다. 이 방식은 비겹침 방식인 $s = 2, z = 2$ 와 비교해 상위 5 개의 오류율을 각각 0.4%와 0.3% 줄여줍니다. 훈련 중에 일반적으로 겹치는 풀링을 가진 모델이 과적합이 약간 더 어렵다는 것을 관찰합니다.

3.5 전체 아키텍처

이제 CNN 의 전체 구조를 설명할 준비가 되었습니다. 그림 2 에 묘사된 것처럼, 그물은 무게가 있는 8 층으로 구성되어 있습니다; 처음 다섯 개는 합성곱 과정이고 나머지 세 개는 완전 연결입니다. 마지막으로 완전히 연결된 계층의 출력은 1000 웨이 소프트맥스에 전달되어 1000 개의 클래스 라벨에 걸쳐 분포를 생성합니다. 우리 네트워크는 다항 로지스틱 회귀 목적을 최대화하는데, 이는 예측 분포 하에서 올바른 라벨의 로그 확률을 훈련 사례 간 평균을 최대화하는 것과 동등합니다.

² 공간 제약으로 이 네트워크를 자세히 설명할 수는 없지만, 여기 제공된 코드와 매개변수 파일로 정확히 명시되어 있습니다: <http://code.google.com/p/cuda-convnet/>.

두 번째, 네 번째, 다섯 번째 합성곱 층의 커널은 동일한 GPU 에 존재하는 이전 계층의 커널 맵과만 연결되어 있습니다(그림 2 참조). 세 번째 합성곱 층의 핵들은 두 번째 층의 모든 핵 사상과 연결되어 있다. 완전 연결된 층의 뉴런들은 이전 층의 모든 뉴런과 연결되어 있습니다. 응답-정규화 층은 1 층과 2 번 합성곱 층을 따릅니다. 다음에 설명된 것과 같은 최대 풀링층 3.4 절에서는 응답-정규화 계층과 다섯 번째 합성곱 층 다섯 번째 합성 계층을 따라갑니다. ReLU 의 비선형성은 모든 합성곱 및 완전 연결 층의 출력에 적용됩니다.

첫 번째 합성곱 계층은 $11 \times 11 \times 3$ 크기의 96 개의 커널을 가진 $224 \times 224 \times 3$ 입력 이미지를 4 픽셀 간격으로 필터링합니다(이는 인접 수용 필드 중심 간 거리입니다)




그림 2: CNN 아키텍처의 일러스트로, 두 GPU 간 책임 구분을 명확히 보여줍니다. 한 GPU 는 그림 상단의 레이어 파트를, 다른 GPU 는 하단의 레이어 파트를 처리합니다. GPU 는 특정 계층에서만 통신합니다. 네트워크의 입력은 150,528 차원이며, 나머지 계층의 뉴런 수는 253,440-186,624-64,896-64,896-43,264-4096-4096-1000 으로 나타난다.

커널 맵 내의 뉴런들)을 사용한다. 두 번째 컨볼루션 계층은 첫 번째 컨볼루션 레이어의 (응답 정규화 및 풀링된) 출력을 입력으로 받아 크기가 $5 \times 5 \times 48$ 의 256 개의 커널로 필터링합니다. 세 번째, 네 번째, 다섯 번째 합성곱 층은 중간에 풀링이나 정규화 계층 없이 서로 연결되어 있습니다. 세 번째 컨볼루션 계층은 크기 $3 \times 3 \times 256$ 의 384 개의 커널이 두 번째 컨볼루션 계층의 (정규화되고 풀링된) 출력에 연결되어 있습니다. 네 번째 합성곱 계층은 크기 $3 \times 3 \times 192$ 인 384 개의 커널을 가지며, 다섯 번째 합성 계층은 크기 $3 \times 3 \times 192$ 인 256 개의 커널을 포함한다. 완전히 연결된 층들은 각각 4096 개의 뉴런을 가지고 있습니다.

4 과적합 감소

우리의 신경망 아키텍처는 6 천만 개의 매개변수를 가지고 있습니다. ILSVRC 의 1000 개 클래스는 각 훈련 예제가 이미지에서 라벨로의 매핑에 10 비트의 제약을 가하도록 하지만, 이는 상당한 과적합 없이 이렇게 많은 매개변수를 학습하기에 충분하지 않다는 것이 드러났습니다. 아래에서는 과적합을 극복하는 두 가지 주요 방법을 설명합니다.

4.1 데이터 증강

이미지 데이터의 과적합을 줄이는 가장 쉽고 일반적인 방법은 라벨 보존 변환(예: [25, 4, 5])을 사용하여 데이터셋을 인위적으로 확장하는 것입니다. 우리는 두 가지 서로 다른 형태의 데이터 증강을 사용하는데, 이 두 방식 모두 원본 이미지에서 변환된 이미지를 거의 계산하지 않고도 생성할 수 있어, 변환된 이미지를 디스크에 저장할 필요가 없습니다. 우리 구현에서는 변환된 이미지가 CPU 에서 Python 코드로 생성되는 동안 GPU 는 이전 이미지 배치를 기반으로 학습합니다. 따라서 이러한 데이터 증강 방식은 사실상 계산 비용이 자유롭습니다.

첫 번째 형태의 데이터 증강은 이미지 번역과 수평 반사를 생성하는 것입니다. 우리는 256×256 이미지에서 무작위로 224×224 개의 패치(및 그 수평 반사)를 추출하여 이 추출된 패치를 기반으로 네트워크를 훈련시켜³ 이를 수행합니다. 이로 인해 훈련 세트 크기가 2048 배 증가했지만, 결과적으로 학습 예제들은 물론 매우 상호 의존적입니다. 이 방식이 없으면 우리 네트워크는 상당한 과적합 문제를 겪게 됩니다. 그랬다면 훨씬 작은 네트워크를 사용해야 했을 것입니다. 테스트 시점에 네트워크는 224×224 패치 다섯 개(네 모서리 패치와 중앙 패치)와 이들의 수평 반사(총 10 개 패치)를 추출하여 예측을 수행하고, 네트워크의 소프트맥스 계층이 10 개 패치에 대해 예측한 값을 평균화합니다.

두 번째 형태의 데이터 증강은 훈련 이미지에서 RGB 채널의 강도를 변경하는 것입니다. 구체적으로, ImageNet 훈련 세트 전반에 걸친 RGB 픽셀 값 집합에 대해 PCA 를 수행합니다. 각 학습 이미지에 찾은 주성분의 배수를 더하며, 크기는 해당 고유값에 평균 0, 표준편차 0.1 인 가우시안에서 추출한 확률 변수에 비례합니다. 따라서 각 RGB 이미지 픽셀 $I_{xy} = [I_{xy}^R, I_{xy}^G, I_{xy}^B]^T$ 에 다음 양을 더합니다:

$$[\mathbf{p}_1, \mathbf{p}_2, \mathbf{p}_3][\alpha_1 \lambda_1, \alpha_2 \lambda_2, \alpha_3 \lambda_3]^T$$

여기서 $\mathbf{p}_i$ 와 λ_i 는 각각 RGB 픽셀 값의 3×3 공분산 행렬의 i th 고유벡터와 고유값이며, α_i 는 앞서 언급한 확률 변수이다. 각 α_i 는 특정 학습 이미지의 모든 픽셀에 대해 한 번만 그려지며, 그 이미지가 다시 학습에 사용되면 다시 그려집니다. 이 체계는 자연 이미지의 중요한 특성, 즉 조명의 강도와 색상 변화에 객체 동일성이 불변한다는 점을 대략적으로 포착합니다. 이 방식은 상위 1 위 오류율을 1% 이상 줄여줍니다.

4.2 중도 중도

여러 모델의 예측을 결합하는 것은 테스트 오차를 줄이는 매우 성공적인 방법이지만[1, 3], 이미 며칠이 걸리는 대형 신경망에는 너무 비용이 많이 드는 것으로 보입니다. 하지만 훈련 중 약 2 배 정도의 비용이 드는 매우 효율적인 모델 조합 버전도 있습니다. 최근에 도입된 기법인 '드롭아웃(dropout)'[10]은 각 숨겨진 뉴런의 출력을 0.5 의 확률로 0 으로 설정하는 것입니다. 이렇게 '드롭아웃'된 뉴런은 순방향 전달에 기여하지 않으며 역전파에도 참여하지 않습니다. 그래서 입력이 제시될 때마다 신경망은 서로 다른 아키텍처를 샘플링하지만, 이 모든 아키텍처는 가중치를 공유합니다. 이 기술은 특정 다른 뉴런의 존재에 의존할 수 없기 때문에 뉴런 간의 복잡한 공동적응을 줄여줍니다. 따라서 다른 뉴런의 다양한 무작위 하위 집합과 함께 유용한 더 견고한 특징들을 학습할 수밖에 없습니다. 테스트 시점에는 모든

³ 이 때문에 그림 2 의 입력 이미지가 $224 \times 224 \times 3$ 차원입니다.

뉴런을 사용하지만, 그 출력에 0.5 를 곱하는데, 이는 지수적으로 많은 드롭아웃 네트워크가 생성하는 예측 분포의 기하평균을 취하는 것과 합리적인 근사치입니다.

그림 2 의 첫 두 완전 연결 층에서 드롭아웃을 사용합니다. 드롭아웃이 없으면, 우리 네트워크는 상당한 과적합을 보입니다. 드롭아웃은 수렴에 필요한 반복 횟수를 대략 두 배로 늘립니다.

5 학습 세부사항

우리는 128 개의 배치 크기, 운동량 0.9, 그리고



$$w_{i+1} := 0.9 \cdot w_i - 0.0005 \cdot \epsilon \cdot w_i - \epsilon \cdot \left\langle \frac{\partial L}{\partial w} \Big|_{w_i} \right\rangle_{D_i}$$

무게 감쇠 0.0005. 이 작은 무게 감소가 모델이 학습하는 데 중요하다는 것을 발견했습니다. 즉, 여기서 가중치 감소는 단순한 규칙성을 넘어 모델의 훈련 오차를 줄여줍니다. 무게 w 에 대한 업데이트 규칙은 다음과 같았습니다

그림 3: 224×224× 3 입력 이미지의 첫 번째 합성곱층에서 학습 된 크기 11×11×3 의 96 개의 합성곱 커널. 상위 48 개의 커널은 GPU 1 에서 학습되었습니다.

the bottom 48 kernels were learned on GPU 2. See Section 6.1 for details.

$$w_{i+1} := w_i + v_{i+1}$$

여기서 i 는 반복 지수, v 는 운동량 변수, $\left\langle \frac{\partial L}{\partial w} \Big|_{w_i} \right\rangle_{D_i}$ 는 학습률, 그리고 w 에 대한 목적 미분 의 i 번째 배치 D_i 에 대한 평균이며, w_i 에서 평가된다.

각 층의 가중치를 표준편차 0.01 의 0 평균 가우시안 분포에서 초기화했습니다. 우리는 2, 4, 5 번째 합성곱 층과 완전히 연결된 숨겨진 층에서 뉴런 바이어스를 상수 1 로 초기화했습니다. 이 초기화는 ReLU 에 긍정적인 입력을 제공하여 학습 초기 단계를 가속화합니다. 나머지 층의 뉴런 편향을 상수 0 으로 초기화했습니다.

모든 계층에 대해 동일한 학습률을 사용했고, 훈련 내내 수동으로 조정했습니다. 우리가 따랐던 휴리스틱은 검증 오류율이 현재 학습률에 따라 개선되지 않을 때 학습률을 10 으로 나누는 것이었습니다. 학습률은 0.01 로 초기화되었고, 종료 전 세 차례 감소했습니다. 우리는 120 만 장의 이미지 훈련 세트를 통해 약 90 사이클 동안 네트워크를 훈련했으며, 이 과정은 두 개의 NVIDIA GTX 580 3GB GPU 에서 5 일에서 6 일이 걸렸습니다.

6 결과

ILSVRC-2010 에 대한 우리의 결과는 표 1 에 요약되어 있습니다. 우리 네트워크는 테스트 세트에서 37.5%와 17.0%의 상위 1 위와 상위 5 위 오류율을 달성하고 있습니다. ILSVRC2010 대회에서 달성한 최고 성과는 각각 47.1%와 28.2%였으며, 서로 다른 특징에 대해 훈련된 6 개의 희소 코딩 모델에서 생성된 예측값을 평균화한 접근법에서 나왔으며[2], 이후 최고 출판 결과는 45.7%와 25.7%이며, 두 가지 밀집된 특징에서 계산된 피셔 벡터(FV)로 학습된 두 분류기의 예측을 평균화하는 접근법을 적용 했습니다[24].

또한 ILSVRC-2012 대회에 모델을 출품했으며, 결과를 표 2 에 보고합니다. ILSVRC-2012 테스트 세트 라벨은 공개되지 않으므로, 모든 모델에 대해 테스트 오류율을 보고할 수 없습니다.

Model	Top-1	Top-5
<i>Sparse coding [2]</i>	47.1%	28.2%
<i>SIFT + FVs [24]</i>	45.7%	25.7%
CNN	37.5%	17.0%

표 1: ILSVRC2010 테스트 세트 결과 비교.
이탤릭체는 다른 사람들이 달성한
최고의 결과를 나타냅니다.

우리는 노력했어요. 이 단락의 나머지 부분에서는
검증과 테스트 오류율을 서로 바꿔 사용하는데, 이는
저희 경험상 두 오류의 차이가 0.1%를 넘지 않기
때문입니다(표 2 참조). 이 논문에서 설명된 CNN 은
다음과 같은 성과를 냅니다

상위 5 위 오류율은 18.2%입니다. 다섯 개의 유사한 CNN 의 예측을 평균으로 합치하면
오류율이 16.4%입니다. 하나의 CNN 을 훈련시키고, 마지막 풀링 계층 위에 여섯 번째 합성곱
층을 추가하여 ImageNet 2011 년 가을 릴리스 전체(15M 이미지, 22K 카테고리)를 분류한 후,
ILSVRC-2012 에서 "미세 조정"하면 오류율이 16.6%에 달합니다. 2011 년 가을 전체 릴리스에서
앞서 언급한 다섯 개의 CNN 으로 사전 학습된 두 CNN 의 예측을 평균 내면 오류율은
15.3%입니다. 두 번째로 우수한 대회 출품작은 다양한 유형의 FV 에서 학습된 여러 분류기의
예측을 평균화하는 접근법으로 26.2%의 오류율을 기록했습니다. 밀집 샘플링 특징 [7].

Model	Top-1 (val)	Top-5 (val)	Top-5 (test)
<i>SIFT + FVs [7]</i>	—	—	26.2%
1 CNN	40.7%	18.2%	—
5 CNNs	38.1%	16.4%	16.4%
1 CNN*	39.0%	16.6%	—
7 CNNs*	36.7%	15.4%	15.3%

표 2: ILSVRC-2012 검증 및 테스트 세트의 오류율 비교.

이탤릭체는 다른 사람들이 달성한 최고의 결과를 나타냅니다.

별표*가 붙은 모델은 ImageNet 2011 년

가을 전체 릴리스를 분류하도록 "사전 학습"되었습니다.

그림 4 의 왼쪽 패널에서는 네트워크가 8 장의 테스트 이미지에 대해 상위 5 가지 예측을 계산하여 학습한 내용을 정성적으로 평가합니다. 왼쪽 상단의 진드기처럼 중심에서 벗어난 물체도 그물에 의해 인식될 수 있다는 점에 주목하세요. 상위 5 위 라벨 대부분은 합리적으로 보입니다. 예를 들어, 표범을 그럴듯하게 부르는 이름은 다른 종류의 고양이뿐입니다. 경우에 따라 (그릴, 체리 등) 사진의 의도된 초점에 대해 진정한 모호함이 존재합니다.

네트워크의 시각적 지식을 탐구하는 또 다른 방법은 마지막 4096 차원 숨겨진 층에서 이미지가 유도하는 특징 활성화를 고려하는 것입니다. 두 이미지가 작은 유클리드 간격을 가진 특징 활성화 벡터를 생성한다면, 신경망의 상위 수준에서는 이들을 유사하다고 간주할 수 있습니다. 그림 4 는 이 측정값에 따라 테스트 세트에서 나온 다섯 장의 이미지와 각 세트와 가장 유사한 여섯 장의 이미지를 보여줍니다. 픽셀 수준에서 검색된 훈련 이미지는 일반적으로 첫 번째 열의 쿼리 이미지와 l_2 에서 가깝지 않다는 점을 주목하세요. 예를 들어, 회수된 개와 코끼리는 다양한 포즈로 등장합니다. 추가 자료에서 더 많은 테스트 이미지에 대한 결과를 제시합니다.

두 개의 4096 차원 실수 벡터 간 유클리드 거리를 이용해 유사성을 계산하는 것은 비효율적이지만, 자동 인코더를 훈련시켜 이 벡터들을 짧은 이진 코드로 압축함으로써 효율적으로 만들 수 있습니다. 이는 이미지 라벨을 사용하지 않아 의미론적으로 유사하든 없든 엣지 패턴이 유사한 이미지를 가져오는 경향이 있는 원시 픽셀에 자동 인코더를 적용하는 것보다 훨씬 나은 이미지 검색 방법을 제공할 것입니다 [14].

7 토론

우리의 결과는 크고 심층적인 합성곱 신경망이 순수 지도 학습을 통해 매우 어려운 데이터셋에서 기록적인 성과를 낼 수 있음을 보여줍니다. 단일 컨볼루션 계층이 제거되면 네트워크 성능이 저하된다는 점이 주목할 만합니다. 예를 들어, 중간 계층을 제거하면 네트워크의 상위 1 위 성능이 약 2% 손실됩니다. 그래서 깊이가 결과를 달성하는 데 정말 중요합니다.

실험을 단순화하기 위해, 우리는 비지도 사전 학습을 사용하지 않았지만, 네트워크 크기를 크게 늘리고 라벨 데이터 양이 증가하지 않는 상황에서 도움이 될 것으로 기대했습니다. 지금까지 네트워크를 확장하고 훈련 시간을 늘리면서 결과는 개선되었지만, 인간 시각 시스템의 측두하 경로를 맞추려면 아직 수십 배 더 가야 합니다. 궁극적으로 우리는 비디오 시퀀스에 매우 크고 깊은 합성곱 그물을 사용하고자 하며, 시간 구조가 정적인 이미지에서는 누락되거나 덜 명확한 정보를 제공하는 매우 유용한 정보를 제공하고자 합니다.

참고문헌

- R.M. 벨과 Y. 코렌. 넷플릭스 상금 챌린지에서 얻은 교훈. *ACM SIGKDD 탐사 뉴스레터*, 9(2):75–79, 2007 년.
- A. 버그, J. 덩, L. 페이페이. 대규모 시각 인식 챌린지 2010. www.image-net.org/challenges. 2010.
- L. 브레이먼. 무작위 숲. *머신러닝*, 45(1):5–32, 2001.

- D. 키레스 상, U. 마이어, J. 슈미트후버. 이미지 분류를 위한 다열 심층 신경망. *ArXiv 사전 인쇄본 arXiv:1202.2745*, 2012.
- D.C. 키레스 상, U. 마이어, J. 마스키, L.M. 감바르델라, J. 슈미트후버. 시각적 객체 분류를 위한 고성능 신경망. *Arxiv 사전 인쇄본 arXiv:1102.0183*, 2011.
- J. 덩, W. 동, R. 소처, L.-J. 리, K. 리, 그리고 L. 페이페이. ImageNet: 대규모 계층적 이미지 데이터베이스. *CVPR09*, 2009.
- J. 덩, A. 버그, S. 사티시, H. 수, A. 코슬라, L. 페이페이. *ILSVRC-2012*, 2012. URL <http://www.image-net.org/challenges/LSVRC/2012/>.
- L. 페이페이, R. 퍼거스, 그리고 P. 페로나. 몇 가지 훈련 예제에서 생성 시각 모델 학습: 101 개 객체 범주에서 테스트된 점진적 베이저안 접근법. *컴퓨터 비전 및 영상 이해*, 106(1):59–70, 2007.
- G. 그리핀, A. 홀럽, P. 페로나. Caltech-256 객체 분류 데이터셋. 캘리포니아 공과대학교 기술 보고서 7694, 2007. URL <http://authors.library.caltech.edu/7694>.
- G.E. 힌턴, N. 스리바스타바, A. 크리제프스키, I. 수츠케버, R.R. 살라쿠티노프. 특징 검출기의 공동 적응을 방지하여 신경망을 개선합니다. *arXiv 사전 인쇄본 arXiv:1207.0580*, 2012.
- K. 자렛, K. 카부크쿠오글루, M. A. 란자토, Y. 르쿤. 객체 인식을 위한 최고의 다단계 아키텍처는 무엇인가? *국제 컴퓨터 비전 학술대회*, 2146–2153 쪽. IEEE, 2009.
- A. 크리제프스키. 작은 이미지에서 여러 겹의 특징을 배우는 것. 석사 논문, 토론토 대학교 컴퓨터과학과, 2009 년.
- A. 크리제프스키. cifar-10 의 합성곱 심층 신경 네트워크. *미출간 원고*, 2010 년.
- A. 크리제프스키와 G.E. 힌턴. 콘텐츠 기반 이미지 검색을 위해 매우 깊은 오토인코더를 사용합니다. *ESANN*, 2011.
- Y. 르 쿤, B. 보저, J.S. 덴커, D. 헨더슨, R.E. 하워드, W. 허버드, L.D. 재켈 등. 역전파 네트워크를 이용한 손글씨 숫자 인식. *신경 정보 처리 시스템의 발전*, 1990.
- Y. 르쿤, F.J. 황, L. 보투. 자세와 조명에 대한 불변성을 가진 일반 객체 인식 방법을 배우는 방법. *컴퓨터 비전 및 패턴 인식, 2004. CVPR 2004. 2004 년 IEEE 컴퓨터 학회 학회 논문집*, 제 2 권, II–97 쪽. IEEE, 2004.
- Y. 르쿤, K. 카부크쿠오글루, C. 파라벳. 시각에서의 합성 네트워크와 응용. *2010 년 IEEE 국제 심포지엄 논문집 253–256 쪽 Circuits and Systems (ISCAS) IEEE*, 2010.
- H. Lee, R. Grosse, R. Ranganath, A.Y. Ng. 계층적 표현의 확장 가능한 비지도 학습을 위한 합성곱 심층 신경 네트워크. 제 26 회 국제 머신러닝 연례 학술대회 논문집, 609–616 쪽. ACM, 2009.
- T. 멘싱크, J. 베르베이크, F. 페로닌, 그리고 G. 추르카. 대규모 이미지 분류를 위한 계량 학습: 거의 무비용으로 새로운 클래스로 일반화하기. *ECCV - 유럽 컴퓨터 비전 학술대회*, 이탈리아 피렌체, 2012 년 10 월.
- V. 네어와 G. E. 힌튼. 정류된 선형 유닛은 제한된 볼츠만 기계를 개선합니다. *2010 년 제 27 회 국제 머신러닝 학술대회 논문집*.
- N. 핀토, D.D. 콕스, J.J. 디카를로. 왜 실제 시각 대상을 인식하는 것이 어려운가? *PLoS 계산생물학*, 4(1):e27, 2008.
- N. 핀토, D. 두칸, J.J. 디카를로, D.D. 콕스. 생물학적으로 영감을 받은 시각 표현의 좋은 형태를 발견하기 위한 고처리량 선별 접근법. *PLoS 계산생물학*, 5(11):e1000579, 2009.
- B.C. 러셀, A. 토랄바, K.P. 머피, W.T. 프리먼. Labelme: 이미지 주석을 위한 데이터베이스 및 웹 기반 도구입니다. *국제 컴퓨터 비전 저널*, 77(1):157–173, 2008.

- J. 산체스와 F. 페로닌. 대규모 이미지 분류를 위한 고차원 서명 압축. *컴퓨터 비전 및 패턴 인식(CVPR), 2011 년 IEEE 학술대회*, 1665–1672 쪽. IEEE, 2011.
- P.Y. 시마르, D. 스타인크라우스, J.C. 플랫. 시각적 문서 분석에 적용된 합성곱 신경망의 모범 사례. *제 7 회 국제 문서 분석 및 인식 학술대회/회보*, 제 2 권, 958–962 쪽, 2003 년.
- S.C. 투라가, J.F. 머레이, V. 자인, F. 로스, M. 헬름슈테더, K. 브릭먼, W. 덴크, H.S. 승. 합성곱 네트워크는 이미지 분할을 위한 친화도 그래프를 생성하는 법을 배울 수 있습니다. *신경 계산*, 22(2):511–538, 2010.